Лабораторная работа 1

Аудит и подготовка данных информационной безопасности

Цель работы

- Научиться описывать прикладную задачу информационной безопасности через объект анализа, признаки и целевую переменную.
- Освоить первичный аудит табличного датасета: проверку типов данных, пропусков, дубликатов, выбросов, дисбаланса классов и потенциальных утечек.
- Выполнить корректное разделение данных и собрать воспроизводимый конвейер предварительной обработки с использованием pandas и scikit-learn.
- Сформулировать ограничения датасета и риски, которые могут исказить результат последующего ML-эксперимента.

Задачи

- подготовить Jupyter Notebook и зафиксировать программное окружение;
- составить паспорт датасета и формально определить объект, признаки и целевую переменную;
- исследовать качество, структуру и распределения данных;
- найти признаки возможной утечки и выбрать обоснованную схему разделения;
- собрать preprocessing pipeline, обучаемый только на тренировочной части данных;
- проверить результат преобразования и сформулировать минимум три риска качества данных.

Исходные данные

Все студенты используют единый файл auth_events_lab01.xlsx. Каждая строка листа «Данные» описывает одну попытку аутентификации пользователя. Целевая переменная is_suspicious принимает значение 1 для подозрительного события и 0 для нормального события.

*Предупреждение**.** Не изменяйте исходный Excel-файл вручную. Все проверки, нормализация значений, удаление строк и формирование признаков должны быть воспроизводимы в Notebook.*

Программные средства

- Python 3.11 или совместимая версия, Jupyter Notebook или JupyterLab;
- pandas, numpy, matplotlib, seaborn, openpyxl и scikit-learn;;
- версии Python, pandas и scikit-learn фиксируются в первой части Notebook.

Распределение вариантов

Вариант определяется по номеру студента N в списке группы: номера 1, 4, 7 и далее выполняют вариант 1; номера 2, 5, 8 и далее - вариант 2; номера 3, 6, 9 и далее - вариант 3.

Преподаватель может назначить другой вариант индивидуально.

Вариант	Фокус анализа	Поля	Основная проверка
1	Сетевой и географический контекст попытки входа	source_ip, country, distance_from_usual_km, new_country, vpn_used	Групповое разделение по source_ip
2	Профиль учетной записи и интенсивность входов	user_id, department, auth_method, failed_attempts_24h, login_velocity_1h, account_age_days, password_age_days	Групповое разделение по user_id
3	Устройство и время события	timestamp, hour, is_weekend, device_type, os_family, browser_family, known_device	Временное разделение по timestamp

Важно для варианта 1. Исследуется источник попытки аутентификации, а не полный сетевой поток. Поэтому destination_ip или домен назначения для выполнения варианта не требуются.

Подготовка проекта

Создайте папку lab01_<группа>_<фамилия>. Внутри подготовьте каталог data, Jupyter Notebook lab01.ipynb и при необходимости каталог artifacts.

Поместите auth_events_lab01.xlsx в каталог data. Не изменяйте исходный файл вручную. Все исправления данных должны выполняться кодом в Notebook.

В первой ячейке Notebook импортируйте библиотеки, задайте RANDOM_STATE = 42 и выведите версии Python, pandas и scikit-learn.

Перед сдачей перезапустите ядро и выполните команду Run All. Все ячейки должны выполняться последовательно без ручного изменения промежуточных переменных.

```
from pathlib import Path
import sys
import numpy as np
```

```
import pandas as pd
import sklearn

RANDOM_STATE = 42
DATA_PATH = Path('data/auth_events_lab01.xlsx')

print(sys.version)
print('pandas:', pd.__version__)
print('scikit-learn:', sklearn.__version__)
```

Постановка задачи

Сформулируйте прикладную задачу ИБ одним абзацем: какое событие требуется оценить, кто использует результат и какое действие может быть принято.

Укажите объект анализа и гранулярность наблюдения. Объясните, почему одна строка соответствует одной попытке аутентификации, а не пользователю или инциденту.

Укажите целевую переменную is_suspicious и расшифруйте значения классов. Не используйте название класса как доказательство корректности разметки.

Опишите происхождение набора, дату получения, исходный размер и ограничения синтетических данных.

Составьте собственную таблицу признаков: название столбца, смысл, фактический тип, ожидаемый тип, допустимые значения, момент доступности и решение об использовании.

Обязательный результат раздела. Паспорт датасета, формальная постановка задачи и таблица признаков. Должно быть понятно, что является X, что является y и в какой момент каждый признак доступен средству защиты.

Загрузка и первичная инвентаризация

Загрузите лист «Данные» файла auth_events_lab01.xlsx средствами pandas.

Выведите первые и последние строки, размер таблицы, названия столбцов, типы данных и объем памяти.

Проверьте, что число строк соответствует числу объектов, а целевой столбец присутствует ровно один раз.

Для числовых признаков выведите описательные статистики. Для категориальных - число уникальных значений и наиболее частые категории.

Сохраните исходное число строк и столбцов в переменные, чтобы далее показать, какие изменения внесены очисткой.

Проверка типов и допустимых значений

Сопоставьте фактический тип каждого столбца с его смыслом. Найдите числовые значения, загруженные как строки, смешанные форматы дат и категориальные признаки с ошибочными вариантами написания.

Сформулируйте предметные ограничения для счетчиков, расстояний, возраста учетной записи и бинарных признаков. Проверьте, какие строки нарушают эти ограничения.

Исправляйте типы и очевидные технические ошибки кодом. Не заменяйте подозрительное значение молча: посчитайте количество исправленных строк и объясните решение.

Анализ пропусков

Рассчитайте число и долю пропусков для каждого столбца. Покажите только столбцы, в которых пропуски обнаружены, отсортировав их по убыванию доли.

Проверьте, не скрываются ли пропуски под значениями "?", "unknown", "-", пустой строкой, нулем или другим условным обозначением.

Для каждого проблемного признака выберите действие: оставить, удалить столбец, удалить отдельные строки или заполнить значение внутри pipeline. Обоснуйте решение с позиции смысла признака.

Целевую переменную автоматически не заполняйте. Строки без надежной метки отделите и объясните, можно ли использовать их в обучении с учителем.

Поиск дубликатов и зависимых объектов

Посчитайте полные дубликаты строк и покажите несколько примеров. Отдельно проверьте повторения event_id и последовательности событий одного user_id.

Определите, являются ли повторения ошибкой сбора, повторным наблюдением реального события или копиями одного объекта. Полные технические копии удалите кодом, сохранив число удаленных строк.

Проверьте, могут ли связанные события одного пользователя попасть одновременно в train и test. Объясните, как это влияет на достоверность проверки модели.

Выбросы и подозрительные значения

Выберите не менее трех содержательно важных числовых признаков и исследуйте их распределения с помощью квантилей, boxplot или гистограммы.

Найдите крайние значения методом межквартильного размаха, робастных квантилей или предметных ограничений. Укажите число и долю отмеченных объектов.

Не удаляйте выбросы автоматически. В задачах ИБ редкое значение может быть ошибкой измерения, нормальной редкой активностью или самой атакой. Для каждого признака сформулируйте правило обработки.

Если используется обрезка значений, пороги должны оцениваться по train и применяться к

test без повторного подбора.

Дисбаланс целевой переменной

Посчитайте абсолютное число и долю объектов каждого класса.

Постройте столбчатую диаграмму распределения целевой переменной. На диаграмме должны быть подписи классов и числовые значения.

Объясните, соответствует ли полученное распределение реальной системе. Укажите, какой класс является редким и почему обычная accuracy в дальнейшем может быть недостаточна.

На этом этапе не применяйте oversampling, undersampling или SMOTE ко всему датасету. Такие операции допускаются только после разделения и только внутри тренировочного контура.

Поиск потенциальной утечки данных

Для каждого столбца ответьте, было ли его значение известно в момент попытки аутентификации, когда средство защиты должно принять решение.

Проверьте, нет ли поля, которое прямо или почти прямо кодирует целевую метку. Подтвердите вывод количественно, но не используйте будущую модель как единственное доказательство.

Отдельно оцените служебные идентификаторы, время события, IP-адрес, учетную запись и результаты последующей обработки события. Объясните риск запоминания объектов вместо общей закономерности.

Проверьте, не могут ли полные дубликаты или связанные события одного пользователя оказаться одновременно в train и test.

Составьте реестр всех подозрительных полей: поле, момент появления, тип риска, решение оставить или исключить и обоснование.

Выбор и выполнение разделения

Сначала отделите целевую переменную y от матрицы признаков X и исключите согласованные признаки утечки.

Сравните три возможные схемы: стратифицированную случайную, групповую по user_id и временную по timestamp. Выберите одну основную схему и объясните, какое эксплуатационное условие она проверяет.

Используйте ориентировочно 80% объектов для train и 20% для test. Иное соотношение допускается при обосновании.

Для случайного разделения зафиксируйте RANDOM_STATE и примените stratify=y, если каждый класс содержит достаточно объектов.

Для группового разделения докажите, что пересечение групп train и test пусто. Для

временного - докажите, что максимальное время train не позже минимального времени test.

Сравните размер и распределение целевой переменной в train и test. Существенные различия объясните.

Построение preprocessing pipeline

Разделите признаки на числовые и категориальные. Даты, свободный текст, IP-адреса и другие специальные типы не включайте механически: сначала определите корректное представление или обоснованно исключите их.

Для числовых признаков предусмотрите заполнение пропусков медианой и масштабирование StandardScaler или RobustScaler. Выбор масштабирования кратко объясните.

Для категориальных признаков предусмотрите заполнение наиболее частым значением и OneHotEncoder(handle_unknown="ignore").

Соберите ColumnTransformer, а затем общий Pipeline. Все операции, оценивающие параметры по данным, должны обучаться только методом fit или fit_transform на X_train.

Преобразуйте X_train методом fit_transform, а X_test только методом transform. Не вызывайте fit или fit_transform на тестовой части.

Проверка результата преобразования

Выведите размер X_train_ready и X_test_ready. Число строк должно совпадать с y_train и y_test.

Получите названия результирующих признаков методом get_feature_names_out, если используемые преобразования это поддерживают.

Проверьте отсутствие недопустимых NaN и бесконечных значений после преобразования.

Покажите, что preprocessor обучен только на train: код разделения расположен до fit_transform, а к test применяется только transform.

Сохраните pipeline в artifacts/preprocessor.joblib. Сохранение не заменяет проверку воспроизводимости Notebook.

Итоговый аудит и выводы

Составьте итоговую таблицу: обнаруженная проблема, количественная оценка, принятое решение, число затронутых объектов и возможное влияние на будущую модель.

Сравните исходный и подготовленный датасет: число объектов, признаков, пропусков, дубликатов и доли классов.

Сформулируйте не менее трех рисков, способных исказить эксперимент. Минимум один риск должен относиться к качеству данных, один - к разделению или утечке, один - к несоответствию учебных данных реальной системе.

Для каждого риска предложите меру контроля: изменение сбора, групповое или временное разделение, исключение признака, проверку источника, мониторинг распределения или ручную верификацию.

Сделайте итоговый вывод: пригоден ли датасет для последующей лабораторной работы по классификации угроз и при каких ограничениях.

Граница работы. Обучение и сравнение классификаторов в лабораторной работе №1 не требуется. Ее результатом является проверенный датасет, обоснованная схема разделения и воспроизводимый preprocessing pipeline.

Проверка результата

- Notebook выполняется от первой до последней ячейки после Restart Kernel/Run All;
- указаны происхождение набора, объект, целевая переменная и ограничения данных;
- проверены типы, допустимые значения, пропуски, дубликаты, выбросы и дисбаланс;
- составлен реестр потенциальных утечек и обосновано решение по каждому подозрительному признаку;
- разделение выполнено до обучения преобразований и соответствует структуре данных;
- preprocessor использует fit_transform только для train и transform для test;
- зафиксированы версии библиотек и RANDOM_STATE;
- сформулированы минимум три риска и меры контроля;
- в Notebook нет скрытых зависимостей от ранее выполненных ячеек и абсолютных путей к файлам;
- в работе отсутствуют реальные персональные, конфиденциальные и опасные данные.

Отчет по работе

- Отчет оформляется внутри Jupyter Notebook с помощью Markdown-ячеек. Отдельный текстовый документ не требуется. В сдаваемом архиве должны находиться:
- lab01.ipynb со всеми выводами, таблицами и графиками;
- requirements.txt или отдельная Markdown-ячейка с версиями основных библиотек;
- краткий итоговый вывод объемом 8-12 предложений и таблица рисков;
- artifacts/preprocessor.joblib, если объект pipeline сохранялся в ходе работы.
- Файл auth_events_lab01.xlsx повторно прикладывать не требуется, если преподаватель не указал иное. В Notebook путь к данным должен быть относительным.

Имя архива: lab01_<группа>_<фамилия>.zip.

Защита: индивидуальная. Студент демонстрирует Notebook, объясняет решения и по

просьбе преподавателя изменяет одно условие: способ разделения, перечень признаков утечки или стратегию обработки пропусков.

Критерии оценивания

Критерий	**Баллы**	**Признак выполнения**
Работоспособность и полнота решения	4	Все обязательные этапы реализованы, код выполняется последовательно.
Методическая корректность	2	Нет критической утечки, неверного разделения или обучения преобразований на test.
Анализ данных, рисков и выводов	2	Проблемы оценены количественно, приведены минимум три риска и обоснованные меры.
Воспроизводимость и оформление	1	Notebook запускается через Run All, указаны зависимости, пути относительные.
Устная защита	1	Студент объясняет код, данные и принятые решения.
Итого	10	

Критическое ограничение. Работа не может получить более 5 баллов, если данные были разделены после масштабирования, заполнения пропусков, отбора признаков или ресемплинга либо если студент не способен объяснить происхождение признаков и целевой переменной.

Контрольные вопросы

- Что является объектом, признаком и целевой переменной в этой работе?
- Кто будет использовать результат анализа и какое решение может быть принято на его основе?
- Какие ограничения имеет синтетический источник данных?
- Чем пропуск отличается от условного значения unknown или нуля?
- Почему выброс в данных ИБ нельзя автоматически считать ошибкой и удалять?
- Чем полный дубликат отличается от повторного наблюдения реального события?
- Что такое дисбаланс классов и какой класс является редким в наборе?

- Что такое утечка данных в ML-эксперименте?
- Какие поля вы исключили из-за риска прямой утечки или появления после момента решения?
- Почему идентификатор, IP-адрес, учетная запись или временная метка могут дать ложное качество?
- Почему связанные события одного пользователя опасно случайно распределять между train и test?
- Почему данные необходимо разделить до заполнения пропусков и масштабирования?
- Когда применяют стратифицированное, групповое и временное разделение?
- Как вы доказали отсутствие пересечения групп или соблюдение хронологии между train и test?
- Для чего используется ColumnTransformer?
- Чем fit_transform отличается от transform и где применяется каждый метод?
- Зачем OneHotEncoder задают handle_unknown="ignore"?
- Какие параметры обработки данных сохраняются внутри pipeline?
- Какие три риска вы считаете наиболее опасными для этого набора?
- Почему корректно подготовленный учебный датасет еще не гарантирует эффективность детектора в реальной системе?

Рекомендуемые материалы

Pandas User Guide: https://pandas.pydata.org/docs/user_guide/

Scikit-learn: Pipelines and composite estimators: https://scikit-learn.org/stable/modules/compose.html

Scikit-learn: Preprocessing data: https://scikit-learn.org/stable/modules/preprocessing.html

Scikit-learn: Common pitfalls and recommended practices: https://scikit-learn.org/stable/common_pitfalls.html